
06 2개의 층을 연결합니다



전체 샘플에 대해 행렬 곱셈 적용하기

$$XW = \left\{ \begin{array}{c|c} x_1^{(1)} & x_2^{(1)} & x_3^{(1)} \\ \hline x_1^{(2)} & x_2^{(2)} & x_3^{(2)} \\ \hline \vdots & & & \vdots \\ \hline x_1^{(m)} & x_2^{(m)} & x_3^{(m)} \end{array} \right\} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_3 \end{bmatrix} = \begin{bmatrix} x_1^{(1)} w_1 + x_2^{(1)} w_2 + x_3^{(1)} w_3 \\ \hline x_1^{(2)} w_1 + x_2^{(2)} w_2 + x_3^{(2)} w_3 \\ \hline \vdots \\ \hline x_1^{(m)} w_1 + x_2^{(m)} w_2 + x_3^{(m)} w_3 \end{bmatrix}$$

$$(m, n) \cdot (n, k) = (m, k)$$
 np.dot(x, w)

cancer 데이터셋의 정방향 계산

배치 경사 하강법은 전체 데이터셋을 모두 계산한 다음 그레이디언트를 업데이트합니다

$$(364, 30) \cdot (30, 1) = (364, 1)$$

$$xw + b = \begin{bmatrix} x_1^{(1)} & \cdots & x_{30}^{(1)} \\ \vdots & \vdots \\ x_1^{(364)} & \cdots & x_{30}^{(364)} \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_{30} \end{bmatrix}^{30} + \begin{bmatrix} b \\ \vdots \\ b \end{bmatrix}^{364} \begin{bmatrix} z^{(1)} \\ z^{(2)} \\ \vdots \\ z^{(364)} \end{bmatrix}^{364}$$

$$def forpass(self, x):$$

$$z = \text{np.dot}(x, \text{ self.w}) + \text{self.b}$$

$$return z$$

$$\begin{bmatrix} x_1^{(1)} & \cdots & x_{30}^{(1)} \\ \vdots \\ x_1^{(364)} & \cdots & x_{30}^{(364)} \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_{30} \end{bmatrix} + b = \begin{bmatrix} x_1^{(1)} w_1 + x_2^{(1)} w_2 + \cdots + x_{30}^{(1)} w_{30} \\ \vdots \\ x_1^{(364)} w_1 + x_2^{(364)} w_2 + \cdots + x_{30}^{(1)} w_{30} + b \end{bmatrix} + b$$

$$def forpass(self, x):$$

$$z = \text{np.sum}(x * \text{self.w}) + \text{self.b}$$

$$return z$$


$$= \begin{bmatrix} x_1^{(1)} w_1 + x_2^{(1)} w_2 + \cdots + x_{30}^{(1)} w_{30} + b \\ \vdots \\ x_1^{(364)} w_1 + x_2^{(364)} w_2 + \cdots + x_{30}^{(364)} w_{30} + b \end{bmatrix}$$


cancer 데이터셋의 역방향 계산

```
(30, 364) \cdot (364, 1) = (30, 1)
                                                               e^{(2)}
                                                                            g_2
             행렬의 전치
             (364, 30)^T = (30, 364)
                                   def backprop(self, x, err):
def backprop(self, x, err):
                                       m = len(x)
   w_grad = x * err
                                                                         # 가중치에 대한 평균 그레이디언트를 계산합니다.
                                       w_grad = np.dot(x.T, err) / m
   b_grad = 1 * err
                                                                         # 절편에 대한 평균 그레이디언트를 계산합니다.
                                       b_grad = np.sum(err) / m
   return w_grad, b_grad
                                       return w_grad, b_grad
```

```
fit() 메서드 수정
                  for i in range(epochs):
                                                     # epochs만큼 반복합니다.
                     loss = 0
                     indexes = np.random.permutation(np.arange(len(x))) # 인덱스를 섞습니다.
                     for i in indexes:
                                                     # 모든 샘플에 대해 반복합니다.
                        z = self.forpass(x[i])
                                                     # 정방향 계산
                        a = self.activation(z)
                                                     # 활성화 함수 적용
                        err = -(y[i] - a)
                                                     # 오차 계산
                   # epochs만큼 반복합니다.
                   for i in range(epochs):
                       z = self.forpass(x)
                                                        # 정방향 계산을 수행합니다.
                       a = self.activation(z)
                                                        # 활성화 함수를 적용합니다.
                       err = -(y - a)
                                                        # 오차를 계산합니다.
```


cancer 데이터셋에 배치 경사 하강법 적용하기





06-2 2개의 층을 가진 신경망을 구현합니다

하나의 층에 여러 개의 뉴런을 사용합니다




$$x_1w_{11} + x_2w_{21} + x_3w_{31} + b_1 = z_1$$

 $x_1w_{12} + x_2w_{22} + x_3w_{32} + b_2 = z_2$


$$[x_1 x_2 x_3] \begin{bmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \\ w_{31} & w_{32} \end{bmatrix} + [b_1 b_2] = [z_1 z_2]$$

전체 샘플일 경우: $m{X}m{W}_1+m{b}_1=m{Z}_1$

출력을 하나로 모읍니다




은닉층이 추가된 신경망을 알아봅니다




다층 신경망의 개념을 정리합니다


다층 퍼셉트론 == 완전 연결 신경망 == 밀집 신경망 == 피드 포워드 신경망




다층 신경망에 경사 하강법을 적용합니다




가중치에 대해 손실 함수를 미분합니다(출력층)



절편에 대하여 손실 함수를 미분합니다(출력층)



가중치에 대하여 손실 함수를 미분합니다(은닉층)



도함수를 곱합니다(은닉층) - 1

$$\frac{\partial L}{\partial Z_{2}} \frac{\partial Z_{2}}{\partial A_{1}} = -(Y - A_{2})W_{2}^{T} = \begin{bmatrix} 0.7 \\ 0.3 \\ \vdots \\ 0.6 \end{bmatrix} [0.02 \ 0.16] = \begin{bmatrix} 0.014 \ 0.112 \\ \vdots \\ 0.012 \ 0.096 \end{bmatrix} m^{7} + (m, 1) \cdot (1, 2) = (m, 2)$$

$$\frac{\partial L}{\partial Z_{2}} \frac{\partial Z_{2}}{\partial A_{1}} \frac{\partial A_{1}}{\partial Z_{1}} = -(Y - A_{2})W_{2}^{T} \bullet A_{1} \bullet (1 - A_{1})$$


$$= \begin{bmatrix} 0.014 \ 0.112 \\ \vdots \\ 0.012 \ 0.096 \end{bmatrix} \bullet \begin{bmatrix} 2.37 \ 6.10 \\ \vdots \\ 1.81 \ 4.82 \end{bmatrix} \bullet \left(1 - \begin{bmatrix} 2.37 \ 6.10 \\ \vdots \\ 1.81 \ 4.82 \end{bmatrix}\right)$$

$$= \begin{bmatrix} -0.045 \ -3.48 \\ \vdots \\ -0.018 \ -1.768 \end{bmatrix} m^{7} + (m, 1) \cdot (1, 2) \odot (m, 2) = (m, 2)$$


도함수를 곱합니다(은닉층) - 2

 $(3, m)\cdot((m, 1)\cdot(1, 2)\odot(m, 2)) = (3, 2)$

절편에 대하여 손실 함수를 미분하고 도함수를 곱합니다



2개의 층을 가진 신경망 구현하기



```
def forpass(self, x):
  z1 = np.dot(x, self.w1) + self.b1 # 첫 번째 층의 선형식을 계산합니다
  self.a1 = self.activation(z1) # 활성화 함수를 적용합니다
  z2 = np.dot(self.a1, self.w2) + self.b2 # 두 번째 층의 선형식을 계산합니다.
  return z2
```


2개의 층을 가진 신경망 구현하기

역방향 계산

```
\frac{\partial \boldsymbol{L}}{\partial \boldsymbol{W}_2} = \frac{\partial \boldsymbol{L}}{\partial \boldsymbol{Z}_2} \frac{\partial \boldsymbol{Z}_2}{\partial \boldsymbol{W}_2} = \boldsymbol{A}_1^T (\underbrace{-(\boldsymbol{Y} - \boldsymbol{A}_2)}_{\text{err}})
def backprop(self, x, err):
                                                                                                                                                                                             \frac{\partial L}{\partial b_2} = \frac{\partial L}{\partial Z_2} \frac{\partial Z_2}{\partial b_2} = \mathbf{1}^T (\underbrace{-(Y - A_2)}_{\text{err}})
            m = len(x)
                                                  # 샘플 개수
            # 출력층의 가중치와 절편에 대한 그레이디언트를 계산합니다.
            w2_grad = np.dot(self.a1.T, err) / m
                                                                                                                                                                                             \frac{\partial \boldsymbol{L}}{\partial \boldsymbol{Z}_2} \frac{\partial \boldsymbol{Z}_2}{\partial \boldsymbol{A}_1} \frac{\partial \boldsymbol{A}_1}{\partial \boldsymbol{Z}_1} = -(\boldsymbol{Y} - \boldsymbol{A}_2) \boldsymbol{W}_2^T \boldsymbol{\odot} \boldsymbol{A}_1 \boldsymbol{\odot} (1 - \boldsymbol{A}_1)
            b2_grad = np.sum(err) / m
            # 시그모이드 함수까지 그레이디언트를 계산합니다.
            err_to_hidden = np.dot(err, self.w2.T) * self.a1 * (1 - self.a1)
            # 은닉층의 가중치와 절편에 대한 그레이디언트를 계산합니다.
            w1_grad = np.dot(x.T, err_to_hidden) / m
                                                                                                                                                          \frac{\partial \boldsymbol{L}}{\partial \boldsymbol{W}_{1}} = \frac{\partial \boldsymbol{L}}{\partial \boldsymbol{Z}_{2}} \frac{\partial \boldsymbol{Z}_{2}}{\partial \boldsymbol{A}_{1}} \frac{\partial \boldsymbol{A}_{1}}{\partial \boldsymbol{Z}_{1}} \frac{\partial \boldsymbol{Z}_{1}}{\partial \boldsymbol{W}_{1}} = \boldsymbol{X}^{T} (\overbrace{-(\boldsymbol{Y} - \boldsymbol{A}_{2}) \boldsymbol{W}_{2}^{1} \boldsymbol{\circledcirc} \boldsymbol{W}_{2}^{T} \boldsymbol{\circledcirc} (1 - \boldsymbol{A}_{1})})
            b1_grad = np.sum(err_to_hidden, axis=0) / m
            return w1_grad, b1_grad, w2_grad, b2_grad
                                                                                                                                                           \frac{\partial \boldsymbol{L}}{\partial \boldsymbol{b}_1} = \frac{\partial \boldsymbol{L}}{\partial \boldsymbol{Z}_2} \frac{\partial \boldsymbol{Z}_2}{\partial \boldsymbol{A}_1} \frac{\partial \boldsymbol{A}_1}{\partial \boldsymbol{Z}_1} \frac{\partial \boldsymbol{Z}_1}{\partial \boldsymbol{b}_1} = \boldsymbol{1}^T (\overbrace{-(\boldsymbol{Y} - \boldsymbol{A}_2) \boldsymbol{W}_2^1 \boldsymbol{\circledcirc} \boldsymbol{W}_2^T \boldsymbol{\circledcirc} (1 - \boldsymbol{A}_1)}^T)
```

init_weights() 메서드 추가하고 훈련하기


```
def init_weights(self, n_features):
    self.w1 = np.ones((n_features, self.units)) # (특성 개수, 은닉층의 크기)
    self.b1 = np.zeros(self.units) # 은닉층의 크기
    self.w2 = np.ones((self.units, 1)) # (은닉층의 크기, 1)
    self.b2 = 0
```



가중치 초기화 개선하기

06-3 미니 배치를 사용하여 모델을 훈련합니다

```
class MinibatchNetwork(RandomInitNetwork):
   def __init__(self, units=10, batch_size=32, learning_rate=0.1, l1=0, l2=0):
        super( ).__init__(units, learning_rate, l1, l2)
        self.batch_size = batch_size
                                                               # 미니 배치 제너레이터 함수
def fit(self, x, y, epochs=100, x_val=None, y_val=None):
                                                               def gen_batch(self, x, y):
   y = y.reshape(-1, 1)
                                   # 타깃을 열 벡터로 바꿉니다.
                                                                  length = len(x)
                                 # 은닉층과 출력층의 가중치를 최
   self.init_weights(x.shape[1])
                                                                  bins = length // self.batch_size
                                                                                                    # 미니 배치 횟수
   np.random.seed(42)
                                                                  if length % self.batch_size:
   # epochs만큼 반복합니다.
                                                                                                    # 나누어 떨어지지 않을 때
                                                                     bins += 1
   for i in range(epochs):
                                                                  indexes = np.random.permutation(np.arange(len(x))) # 인덱스를 섞습니다.
       loss = 0
                                                                  x = x[indexes]
       # 제너레이터 함수에서 반환한 미니 배치를 순환합니다.
                                                                  y = y[indexes]
       for x_batch, y_batch in self.gen_batch(x, y):
                                                                  for i in range(bins):
           y_batch = y_batch.reshape(-1, 1) # 타깃을 열 벡터로
                                                                     start = self.batch_size * i
                                                                     end = self.batch size * (i + 1)
           m = len(x_batch)
                                             # 샘플 개수를 저장
                                                                      yield x[start:end], y[start:end] # batch_size만큼 슬라이싱하여 반환합니다.
           a = self.training(x_batch, y_batch, m)
```




사이킷런을 사용해 다층 신경망 훈련하기


mlp.fit(x_train_scaled, y_train)
mlp.score(x_val_scaled, y_val)
0.989010989010989


07 여러 개를 분류합니다

- 다중 분류(multiclass classification)

07-1 여러 개의 이미지를 분류하는 다층 신경망을 만듭니다







소프트맥스(softmax) 함수

$$\frac{e^{z_{i}}}{e^{z_{1}} + e^{z_{2}} + e^{z_{3}}}$$

$$\frac{z_{1}}{e^{z_{1}} + e^{z_{2}} + e^{z_{3}}}$$

$$\frac{z_{2}}{e^{z_{1}} + e^{z_{2}} + e^{z_{3}}}$$

$$\frac{z_{2}}{e^{z_{1}} + e^{z_{2}} + e^{z_{3}}}$$

$$\frac{z_{3}}{e^{z_{1}} + e^{z_{2}} + e^{z_{3}}}$$

출력 정규화

$$\hat{y}_1 = \frac{e^{2.20}}{e^{2.20} + e^{1.39} + e^{0.85}} = 0.59 \quad \hat{y}_2 = \frac{e^{1.39}}{e^{2.20} + e^{1.39} + e^{0.85}} = 0.26 \quad \hat{y}_3 = \frac{e^{0.85}}{e^{2.20} + e^{1.39} + e^{0.85}} = 0.15$$

$$\frac{\hat{x} = \underbrace{\text{E}} \text{ off} \hat{A}}{\text{off} \hat{A}} \qquad \qquad \underbrace{\hat{x} = \underbrace{\text{off}} \hat{A}}_{\text{off} \hat{A}} \qquad \qquad \underbrace{\hat{$$

다중 분류를 위한 손실 함수

크로스 엔트로피 손실 함수

$$L = -\sum_{c=1}^{c} y_{c} log(a_{c}) = -(y_{1} log(a_{1}) + y_{2} log(a_{2}) + \dots + y_{c} log(a_{c})) = -1 \times log(a_{y=1})$$


로지스틱 손실 함수

$$L\!=\!-(ylog(a)\!+\!(1\!-\!y)log(1\!-\!a))$$
 $y\!=\!egin{cases} -log\ a & \text{(양성 클래스인 경우)} \\ -log(1\!-\!a) & \text{(음성 클래스인 경우)} \end{cases}$

크로스 엔트로피 손실 함수의 미분

 z_1 에 대한 미분 (다변수 함수의 연쇄 법칙)

$$\frac{\partial L}{\partial z_1} = \frac{\partial L}{\partial a_1} \frac{\partial a_1}{\partial z_1} + \frac{\partial L}{\partial a_2} \frac{\partial a_2}{\partial z_1} + \frac{\partial L}{\partial a_3} \frac{\partial a_3}{\partial z_1}$$




∂L/∂a

$$L\!=\!-(y_1log\ (a_1)\!+\!y_2log(a_2)\!+\!y_3log(a_3))\cdot$$

$$\frac{\partial L}{\partial a_1}\!=\!-\frac{\partial}{\partial a_1}(y_1loga_1\!+\!y_2loga_2\!+\!y_3loga_3)\!=\!-\frac{y_1}{a_1}$$

$$\frac{\partial L}{\partial a_2} = -\frac{y_2}{a_2} \qquad \frac{\partial L}{\partial a_3} = -\frac{y_3}{a_3}$$



$\partial a_1/\partial z_1$

$$a_1 = \frac{e^{z_1}}{e^{z_1} + e^{z_2} + e^{z_3}}$$

$$\begin{split} \frac{\partial a_{1}}{\partial z_{1}} &= \frac{\partial}{\partial z_{1}} \left(\frac{e^{z_{1}}}{e^{z_{1}} + e^{z_{2}} + e^{z_{3}}} \right) = \frac{(e^{z_{1}} + e^{z_{2}} + e^{z_{3}}) \frac{\partial}{\partial z_{1}} e^{z_{1}} - e^{z_{1}} \frac{\partial}{\partial z_{1}} (e^{z_{1}} + e^{z_{2}} + e^{z_{3}})}{(e^{z_{1}} + e^{z_{2}} + e^{z_{3}})^{2}} \\ &= \frac{e^{z_{1}} (e^{z_{1}} + e^{z_{2}} + e^{z_{3}}) - e^{z_{1}} e^{z_{1}}}{(e^{z_{1}} + e^{z_{2}} + e^{z_{3}})^{2}} \\ &= \frac{e^{z_{1}}}{e^{z_{1}} + e^{z_{2}} + e^{z_{3}}} - \left(\frac{e^{z_{1}}}{e^{z_{1}} + e^{z_{2}} + e^{z_{3}}}\right)^{2} = a_{1} - a_{1}^{2} = a_{1}(1 - a_{1}) \end{split}$$

$\partial a_2/\partial z_1$, $\partial a_3/\partial z_1$

$$\begin{split} \frac{\partial a_2}{\partial z_1} = & \frac{\partial}{\partial z_1} \left(\frac{e^{z_2}}{e^{z_1} + e^{z_2} + e^{z_3}} \right) = \frac{(e^{z_1} + e^{z_2} + e^{z_3}) \frac{\partial}{\partial z_1} e^{z_2} - e^{z_2} \frac{\partial}{\partial z_1} (e^{z_1} + e^{z_2} + e^{z_3})}{(e^{z_1} + e^{z_2} + e^{z_3})^2} \\ = & \frac{O - e^{z_2} e^{z_1}}{(e^{z_1} + e^{z_2} + e^{z_3})^2} = -a_2 a_1 \end{split}$$

$$\begin{aligned} \frac{\partial a_3}{\partial z_1} &= \frac{\partial}{\partial z_1} \left(\frac{e^{z_3}}{e^{z_1} + e^{z_2} + e^{z_3}} \right) = \frac{(e^{z_1} + e^{z_2} + e^{z_3}) \frac{\partial}{\partial z_1} e^{z_3} - e^{z_3} \frac{\partial}{\partial z_1} (e^{z_1} + e^{z_2} + e^{z_3})}{(e^{z_1} + e^{z_2} + e^{z_3})^2} \\ &= \frac{O - e^{z_3} e^{z_1}}{(e^{z_1} + e^{z_2} + e^{z_3})^2} = -a_3 a_1 \end{aligned}$$

$\partial L/\partial z_1$

$$\frac{\partial L}{\partial z_1} = \frac{\partial L}{\partial a_1} \frac{\partial a_1}{\partial z_1} + \frac{\partial L}{\partial a_2} \frac{\partial a_2}{\partial z_1} + \frac{\partial L}{\partial a_3} \frac{\partial a_3}{\partial z_1}$$

$$\begin{split} \frac{\partial L}{\partial z_1} &= \left(-\frac{y_1}{a_1}\right) \frac{\partial a_1}{\partial z_1} + \left(-\frac{y_2}{a_2}\right) \frac{\partial a_2}{\partial z_1} + \left(-\frac{y_3}{a_3}\right) \frac{\partial a_3}{\partial z_1} \\ &= \left(-\frac{y_1}{a_1}\right) a_1 (1 - a_1) + \left(-\frac{y_2}{a_2}\right) (-a_2 a_1) + \left(-\frac{y_3}{a_3}\right) (-a_3 a_1) \\ &= -y_1 (1 - a_1) + y_2 a_1 + y_3 a_1 = -y_1 + (y_1 + y_2 + y_3) a_1 = -(y_1 - a_1) \end{split}$$

$$\frac{\partial L}{\partial z} = -(y-a)$$

다중 분류 신경망을 구현합니다

소프트맥스 함수 구현

```
def sigmoid(self, z):
    a = 1 / (1 + np.exp(-z)) # 시그모이드 계산
    return a

def softmax(self, z):
    # 소프트멕스 함수
    exp_z = np.exp(z)
    return exp_z / np.sum(exp_z, axis=1).reshape(-1, 1)

    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.5, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7, 0.2, 0.2, 0.1 ]
    [ : 0.9, 0.8, 0.7, 0.2, 0.2, 0.2, 0.2, 0.2, 0.2 ]
    [ : 0.9, 0.8, 0.7, 0.2, 0.2, 0.2, 0.2, 0
```

init_weights 메서드 수정

```
def init_weights(self, n_features, n_classes):
...
self.w2 = np.random.normal(0, 1, (self.units, n_classes)) # (은닉층의 크기, 클래스 개수)
self.b2 = np.zeros(n_classes)
```

update_val_loss() 메서드 수정

```
def update_val_loss(self, x_val, y_val):
...
a = self.softmax(z) # 활성화 함수를 적용합니다.
...
# 크로스 엔트로피 손실과 규제 손실을 더하여 리스트에 추가합니다.
val_loss = np.sum(-y_val*np.log(a))
...
```

의류 이미지를 분류합니다

패션 MNIST 데이터셋



텐서플로 2.0 설치

현재 코랩에 설치된 텐서플로는 2.3.0입니다. 책에서처럼 수동으로 최신 버전을 설치할 필요가 없습니다.

데이터 준비 (x_train_all, y_train_all), (x_test, y_test) = tf.keras.datasets.fashion_mnist.load_data() print(x_train_all.shape, y_train_all.shape) (60000, 28, 28) (60000,) import matplotlib.pyplot as plt plt.imshow(x_train_all[0], cmap='gray') plt.show()

타깃 확인

```
print(y_train_all[:10])
[9 0 0 3 0 2 7 2 5 5]

class_names = ['티셔츠/윗도리', '바지', '스웨터', '드레스', '코트',
'샌들', '셔츠', '스니커즈', '가방', '앵클부츠']

print(class_names[y_train_all[0]])
앵클부츠

np.bincount(y_train_all)
array([6000, 6000, 6000, 6000, 6000, 6000, 6000, 6000])
```


훈련 세트와 검증 세트 준비


from sklearn.model_selection import train_test_split

```
x_train, x_val, y_train, y_val = train_test_split(x_train_all, y_train_all,
stratify=y_train_all, test_size=0.2, random_state=42)

np.bincount(y_train)
array([4800, 4800, 4800, 4800, 4800, 4800, 4800, 4800, 4800])
np.bincount(y_val)
array([1200, 1200, 1200, 1200, 1200, 1200, 1200, 1200])


x_train = x_train / 255
x_val = x_val / 255
```






to_categorical 함수로 원-핫 인코딩하기

MutliClassNetwork으로 다중 분류 신경망 훈련하기



07-2 텐서플로와 케라스를 사용하여 신경망을 만듭니다



Sequential 모델 훈련하기

